

AI 기반 RFP 문서 분석 RAG Q&A 시스템 구축

최종 프로젝트 보고서

서비스: 입찰메이트 (B2G 입찰지원)

Codeit AI Engineering Bootcamp 8기 — Team 1 (RFP-X)

프로젝트 기간: 2026.05.12 ~ 2026.06.04

역할	팀원
PM / 평가 리드	유연정
Data Processing	정설아, 정봄
Retrieval	박찬영
Generation	박민성

1. 프로젝트 개요

1.1 배경 및 목적

공공기관 RFP(입찰 공고) 문서는 방대한 분량에 전문 용어가 밀집되어 있어, 입찰 참여 기업이 사업 예산·기간·요구사항 등 핵심 정보를 신속하게 파악하기 어렵다. 본 프로젝트는 665개 HWP 파일과 25개 PDF 파일로 구성된 공공기관 RFP 문서를 벡터 데이터베이스에 저장하고, 사용자의 자연어 질문에 대해 관련 청크를 검색·생성하는 RAG(Retrieval-Augmented Generation) 기반 Q&A 시스템을 구축하였다.

1.2 서비스 설정

입찰메이트 (BidMate) B2G(Business-to-Government) 입찰 지원 컨설팅 서비스. 공공기관 RFP 분석 자동화 서비스를 통해 공공 조달 시장 진입 장벽을 낮추는 것을 미션으로 한다.

1.3 팀 구성 및 역할

팀원	담당 파트	주요 역할
유연정	PM / 평가	프로젝트 관리, 평가 데이터셋 구축, 정량/정성 평가, 서빙 구현
정설아	Data Processing	HWP 바이너리 파싱, 청킹 파이프라인, ChromaDB 구축
정봄	Data Processing	PDF 파싱, 청킹 실험, ChromaDB 구축 보조
박찬영	Retrieval	V1~V12 검색 파이프라인 설계 및 고도화
박민성	Generation	LLM 선정 실험, 프롬프트 엔지니어링, 통합 파이프라인


1.4 프로젝트 일정

주차	기간	주요 목표
1주차	05.14 ~ 05.15	환경 세팅, 데이터 탐색, 베이스라인 구축
2주차	05.18 ~ 05.22	파이프라인 고도화, end-to-end 1회 완성
3주차	05.26 ~ 05.29	모델 최적화, 정성 평가, 시나리오 A 완성
4주차	06.01 ~ 06.02	최종 보고서, 서빙, 발표 자료 완성

2. 시스템 아키텍처

2.1 전체 파이프라인

본 시스템은 데이터 처리 → Retrieval → Generation → 서빙의 4단계 파이프라인으로 구성된다.



[그림 1] 전체 파이프라인 구성도

2.2 기술 스택

구분	기술/도구	비고
LLM (서비스용)	gemma4:e4b (Ollama)	한국어+수학+Tool Calling 동시 지원
LLM (프롬프트 실험)	EXAONE-3.5 7.8B (Ollama)	한국어 특화, faithfulness 1.0 달성
임베딩 모델	Qwen/Qwen3-Embedding-0.6B	MTEB 최상위, 119개 언어, 로컬
벡터 DB	ChromaDB (cosine similarity)	51,465개 청크, 영구 저장
검색 전략	Hybrid (BM25 + Dense + RRF)	-
HWP 파싱	olefile + zlib 직접 파싱	표 데이터 포함, 665개 파일
PDF 파싱	pdfplumber + PyMuPDF	25개 파일, 표 Markdown 변환
평가 프레임워크	RAGAS + 커스텀 지표	500건 평가셋, 5개 유형
서빙	Streamlit	BidMate UI, 출처 expander
개발 환경	GCP VM + JupyterLab	팀 공용 서버

2.3 시나리오 구성

구분	시나리오 B (기준)	시나리오 A (최종 채택)
LLM	gpt-5.4-mini (OpenAI API)	gemma4:e4b (Ollama 로컬)
임베딩	text-embedding-3-small (1536d)	Qwen3-Embedding-0.6B (1024d)
청크 수	2,922개	51,465개
API 비용	유 (사용량 비례)	\$0 (완전 로컬)
context_precision	0.722 *	0.214 **
answer_relevancy	0.369 *	0.633 **

* 시나리오 B: Hybrid+Reranker 전략 기준 (청크 2,922개, RAGAS 평가)

** 시나리오 A: V1 Baseline 기준 (청크 51,465개, 20건 샘플) — 평가 조건 차이로 단순 수치 비교 시 주의 필요

3. 데이터 처리 파이프라인

데이터 처리 파트는 정설아(HWP 전담)와 정봄(PDF 전담)이 분담하여 진행하였다. 최종 산출물은 HWP 44,598개 + PDF 6,867개 = 총 51,465개 청크로 구성된 ChromaDB(rfp_seol_chunks_qwen3)이다.

3.1 데이터 현황

파일 유형	파일 수	최종 청크 수	파싱 방식
HWP	665개	44,598개	olefile 바이너리 직접 파싱
PDF	25개	6,867개	pdfplumber + PyMuPDF
합계	690개	51,465개	ChromaDB cosine similarity

3.2 HWP 파싱 파이프라인

파싱 방식 전환 결정

초기에는 data_list_advanced.xlsx의 텍스트 컬럼을 활용하려 했으나, advanced 텍스트에 표 데이터가 전혀 포함되지 않음을 발견하였다. RFP 문서의 평가 기준, 예산, 일정 등 핵심 정보 대부분이 표 형태이므로 olefile을 활용한 원본 바이너리 직접 파싱 방식으로 전환하였다.

항목	advanced 텍스트	원본 바이너리 파싱
표 데이터	0개 (전무)	106개 표 추출 성공
평균 텍스트량	기본 수준	20~50배 증가
핵심 정보 커버	낮음	평가기준표, 일정표 포함

HWP 파싱 라이브러리 선택

HWP를 Python에서 파싱할 수 있는 라이브러리를 먼저 조사하였다.

라이브러리	설치 여부	결과
python-hwp	✗ pip에 없음	사용 불가
hwpx	☑ 설치 가능	API 미지원 — HWP 포맷 파싱 기능 없음
pyhwp	✗ 미채택	2020년 이후 미업데이트, Python 3.10+ 미지원
olefile	☑ 설치 가능	채택 — OLE2 컨테이너 직접 파싱 + zlib 압축 해제

표 추출 로직 개발 — 7회 시도

시도	방식	결과
1~2회	level / payload offset 기반	표 구조 식별 불가 — 실패
3~5회	x좌표 리셋 / TAG_68 ctrl_id	부분 성공 후 퇴행
6회 ☑	TAG_69 size=36 조건	표 104개 추출 성공
7회 ☑	size % 36 == 0 조건 확장	표 106개 — 최종 채택

주요 트러블슈팅

문제	원인	해결
4개 파일 텍스트 없음	압축 안 된 파일에 zlib 무조건 적용	FileHeader 압축 플래그 확인 후 분기
사업개요 청크 누락	is_toc_chunk()가 목차와 사업개요를 같이 제거	사업개요 관련 키워드 예외 조건 추가
누락 문서 1건	로마숫자+숫자 패턴이 목차로 오판	과업개요·과업명 예외 키워드 추가
table chunk 83% 과도	1열 제목 표까지 table로 분류	is_real_table(): 3행+2열 조건으로 변경

3.3 청킹 전략

chunk_size	overlap	총 청크 수	평균 길이	선택
256	50	242,468개	201자	
512	100	120,296개	381자	
1024	200	54,955개	745자	☒ 채택

overlap 실험 (chunk_size=1024 고정)

overlap	총 청크 수	평균 길이	채택
100	54,085개	729자	
200	54,955개	745자	☒ 채택
250	55,796개	753자	

※ 세 가지 overlap 간 청크 수·품질 차이 미미. overlap=200은 chunk_size 대비 약 20%로 일반적 권장 비율에 해당.

청크 유형 분류 (HWP)

chunk_type	청크 수	비율	설명
table	632개	1.4%	2열 이상·3행 이상 실제 데이터 표
summary	10,405개	23.4%	금액·기간·수량 등 수치 패턴 포함
normal	33,521개	75.2%	일반 텍스트 청크
합계 (HWP)	44,558개	100%	최소 50자, 최대 2,000자 / ※ 최종 44,598개와 40개 차이는 is_toc_chunk 2차 수정 분

3.4 ChromaDB 구축

설정 항목	값	선택 이유
컬렉션명	rfp_seol_chunks_qwen3	모델명 포함, 재구축 시 구분 용이
유사도 메트릭	cosine	길이 다른 텍스트 간 유사도 측정에 적합
임베딩 모델	Qwen/Qwen3-Embedding-0.6B	한국어 지원, 경량(0.6B), MTEB 최상위
임베딩 배치 사이즈	8	GPU VRAM 한계를 고려한 배치 크기
저장 배치 사이즈	100청크 단위	대용량 삽입 시 ChromaDB 안정성 확보
최종 청크 수	51,465개	50자 미만 제외 후 최종

3.5 청크 수 변화 이력

날짜	수정 내용	HWP	PDF	총계
초기	—	42,528개	6,867개	49,395개
05.21	사업개요 청크 복구 + PDF 메타 수정	44,528개	6,867개	51,395개
05.22	누락 문서 복구 + 중복 PDF 제거	44,598개	3,664개	48,262개
05.22 이후	PDF 텍스트 청크 복구 (doc_id 오인 수정)	44,598개	6,867개	51,465개 ☒

3.6 파이프라인 개선 (2026-06-02)

ChromaDB 저장 청크의 metadata 누락 버그 5건을 수정하고, 검색 품질 향상을 위한 구조적 개선 2건을 추가 적용하였다.

버그 수정 5건

버그	원인	수정
numeric_summary metadata 누락	청크 최상위 키에만 저장, metadata 딕셔너리 누락 → NUMERIC_CHUNK_BOOST 수치 보정 로직 미동작	HWP/PDF 전체 청크 조립 시 metadata 안에 numeric_summary 추가
PDF 사업금액/광고번호 누락	pdf_text_chunks metadata에 해당 필드 자체 없음 + nan 문자열 저장 버그	PDF 청크 조립 시 두 필드 추가, pd.notna() 처리로 nan 방지
PDF 텍스트 청크 section 경로 오류	unified_pdf_chunks 조립 시 최상위 키 참조 → 항상 빈 값 저장	chunk["metadata"].get("section")으로 경로 수정
inject_title 사업금액 미포함	prefix가 [사업명 발주기관]만 포함 → 금액 질문 임베딩 유사도 낮음	사업금액 있을 경우 [사업명 발주기관 사업금액] 형태로 prefix 확장
PDF 표 청크 section 필드 누락	all_table_chunks metadata에 section 키 없음 → 무결성 체크 오류 3,664건	PDF 표 청크 metadata에 "section": "" 추가

구조 개선 2건

개선	내용	검증 결과
SEPARATORS 조항 경계 패턴 추가	HWP/PDF 공통 SEPARATORS에 ₩n제(조항), ₩n○, ₩n□, ₩n①~⑤, ₩n가.~라. 패턴을 앞순위 추가 → 글자 수 한도 내에서 조항 경계 우선 분리	HWP 10.3%, PDF 21.2% 청크가 조항 경계에서 시작 확인
청크 텍스트에 섹션명 prefix 삽입	섹션명이 metadata에만 있으면 임베딩 시 컨텍스트 미반영 → chunk_document() 내부에서 [섹션: ○○○]₩n을 청크 텍스트 앞에 삽입 (HWP만 적용)	4,665개 청크(10.1%)에 prefix 삽입, 고유 섹션명 2,115개 추출 확인

4. Retrieval 파트

Retrieval 파트는 박찬영이 담당하였다. V1부터 V12까지 총 12회의 버전 업그레이드가 있었다.

4.1 버전별 성능 향상

버전	핵심 변경사항	변경 내용 요약
V1~V3	기본 Dense 검색 및 ChromaDB 구축	
V4	BM25 + Dense Hybrid Search (RRF) 도입	
V5~V6	rewrite / HyDE / MMR / multi_query 전략 추가	전략별 성능 비교 확인
V7	BGE-Reranker 도입 (hybrid_rerank 전략)	재순위화로 정확도 추가 향상
V8	fuzzy matching 필터 + 사업개요 잘림 수정 + nDCG 버그 수정	
V9 ☒	PDF doc_id 수정 데이터 적용 (51,465개 청크)	
V10	D타입 Hallucination 방어 로직 + Recall@10 지표 추가	
V11	text-embedding → Qwen3-Embedding 전환	시나리오 A 전환
V12 ☒	rewrite/hyde LLM → EXAONE 로컬 교체	완전 시나리오 A (API 비용 \$0)

4.2 버전별 고도화 내용

검색 시스템 구성

검색 방식	특징	역할
BM25	키워드 정확도 높음	발주기관명, 사업명 등 고유명사 검색
Dense	의미적 유사도 높음	유사한 의미의 질문 검색
RRF 융합	두 방식 결합	순위를 역수로 변환해 합산

쿼리 전략 7가지

전략	설명	LLM 호출
original	질문 그대로 Dense 검색	없음
hybrid ★	BM25 + Dense + RRF 융합	없음
hybrid_rerank	Hybrid + BGE Reranker	없음
rewrite	EXAONE으로 질문 재작성 후 검색	EXAONE
hyde	EXAONE으로 가상 답변 생성 후 검색	EXAONE
mmr_rewrite	재작성 + MMR 다양성 확보	EXAONE
multi_query	질문 3개로 확장 후 통합 검색	EXAONE x3

발주기관 Fuzzy Matching 임계값

rapidfuzz 라이브러리의 partial_ratio를 활용해 오타나 표현 차이가 있어도 유사한 기관명을 찾아낼 수 있도록 구현하였다.

조건	임계값
짧은 쿼리 (5자 이하)	80 (엄격)
보통 쿼리 (6~10자)	70 (기본)
긴 쿼리 (11자 이상)	60 (완화)

E타입 Hallucination 방어 임계값

Dense score 임계값을 설정해 score가 낮으면 빈 리스트를 반환하도록 방어 로직을 추가하였다. 임계값 0.3 설정 시 E타입 성능 하락 부작용 발생 → 0.2로 조정 후 해결.

임계값	조건	반환
Dense score < 0.2	관련 문서 없음 판단	빈 리스트 반환
RRF score < 0.01	Hybrid 관련 없음 판단	빈 리스트 반환

4.3 주요 트러블슈팅

문제	원인	해결
PDF doc_id 충돌	PDF 청크 ID가 HWP와 겹침	설아님 수정 데이터 적용 (V9)
D타입 임계값 E타입 영향	0.3 임계값이 정상 질문도 차단	0.2로 완화 후 E타입 1.0 복구
rewrite/hyde 0.0	OpenAI API 키 없음 (시나리오 A)	EXAONE Ollama로 교체 (V12)
ChromaDB 경로 불일치	파이프라인 실행 위치에 따라 경로 달라짐	절대 경로로 수정
nDCG@10 = 0.0 버그	binary relevance 처리 오류	relevance label 매핑 방식 수정 (V8)

5. Generation 파트

Generation 파트는 박민성이 담당하였다. 시나리오 B(OpenAI API)를 기준으로 프롬프트 실험을 수행한 후, 시나리오 A(완전 로컬)로 전환하여 최종 서비스 모델을 확정하였다.


5.1 모델 선정 실험

Mac Mini M4 24GB 환경에서 실행 가능한 8개 후보 모델을 대상으로 한국어 성능, 응답 속도, Tool Calling 지원 여부, 수학 계산 정확도를 기준으로 비교하였다.

모델	메모리	한국어	수학	Tool Calling	결과
qwen2.5:7b	~5GB	☆☆☆	☆☆☆	☑	수학 약점으로 탈락
EXAONE-3.5 7.8B	~6GB	☆☆☆☆☆	☆☆☆	✕	프롬프트 실험 채택 (8개 중 1위)
EXAONE 4.0	1.2B/32B	☆☆☆☆☆	☆☆☆☆☆	⚠	Ollama 미공식 지원으로 탈락
qwen3:14b	~10GB	☆☆☆☆	☆☆☆☆	☑	속도 이슈로 보조 사용
phi-4 14B	~10GB	☆☆	☆☆☆☆☆	⚠	한국어 약점으로 탈락
gemma4:e4b	~10GB	☆☆☆☆	☆☆☆☆	☑	최종 서비스 모델 ☑

※ EXAONE-3.5 7.8B: prom_01~09 실험에서 faithfulness 1.0, answer_relevancy 0.55로 8개 후보 중 1위. 단, Tool Calling 미지원으로 gemma4:e4b로 교체.

5.2 프롬프트 개선 실험



[그림 2] 프롬프트 버전별 핵심 개선 흐름 (v1 → v7e)

버전	핵심 변경	주요 효과
v1	역할 정의 + Guardrail + 출처 명시	Baseline
v2	CoT + 3섹션 구조화 + Self-Correction	답변 구조 안정화
v3~v6	금액/기간/비교 처리 규칙 강화	오답률 단계적 감소
v7e ☒	Deterministic Answer + TYPO_REPLACEMENTS + Evidence Card	금액/기간 정확도 대폭 향상

Query Re-writing 효과 (ConversationManagerV2)

지표	v1 (재작성 없음)	v2 (재작성 적용)	개선율
Type B answer_relevancy	0.28	0.53	+89%

5.3 검색 파이프라인 고도화 (시나리오 B)

실험	faithfulness	answer_relevancy	context_precision
Dense Only	0.787	0.312	0.569
BM25 Hybrid	0.913	0.365	0.491
Hybrid + Reranker ☒	0.863	0.369	0.722

5.4 시나리오 A 최종 평가

항목	시나리오 B (p07)	시나리오 A (gemma4)
LLM	gpt-5.4-mini	gemma4:e4b
임베딩	text-embedding-3-small	Qwen3-Embedding-0.6B
청크 수	2,922개	51,465개
평가셋	RAGAS (p07 기준)	20건 샘플 (stratified)
context_precision	0.722	0.214
answer_relevancy	0.369	0.633
API 비용	유	\$0

※ 두 시나리오의 청크 수·평가셋·검색 전략이 달라 수치 단순 비교 시 주의. context_precision은 시나리오 B가 높으나 청크 품질·수량 차이(2,922 vs 51,465)가 주요 변수.

6. 평가

평가 파트는 유연정(PM)이 주도하여 모든 팀원과 함께 정량 평가(Hit@k, MRR, RAGAS)와 정성 평가(타입별 케이스 분석) 두 축으로 진행하였다.

6.1 평가 데이터셋


유형	설명	건수	비율
A	단순 사실 확인 (예산, 수치 등)	150건	30%
B	다중 문서 비교/계산	200건	40%
C	후속 질문 (대화 히스토리 필요)	50건	10%
D	Hallucination 검증	50건	10%
E	오타/구어체 포함 (fuzzy matching)	50건	10%
합계	—	500건	100%

6.2 정량 평가 결과

평가 조건 안내 • Generation 통합 평가: gemma4:e4b 연결 후 20건 stratified 샘플 기준 → Hit@5 = 0.800

Generation 통합 지표 (gemma4:e4b, 20 건 샘플, V1 vs V2) — 박민성

Retrieval + Generation 통합 파이프라인 기준.



[그림 3] Generation 통합 V1 vs V2 주요 지표 비교


지표	V1	V2	변화
Hit@3	0.800	0.800	— 동일
Hit@5	0.800	0.800	— 동일
Hit@10	0.850	0.850	— 동일
MRR@3	0.800	0.725	▼ 하락
Answer Relevancy (RAGAS)	0.633	0.614	▼ 소폭 하락
Context Precision (RAGAS)	0.214	0.228	▲ 개선
False Refusal Rate	22.2%	16.7%	☑ 개선
Wrong Amount Rate	28.6%	37.5%	⚠ 악화
Source Missing Rate	0%	0%	☑ 유지
평균 응답 시간	20.82초	20.09초	☑ 개선

※ Generation 통합 평가 요약

구분	평가 조건	Hit@5	MRR
Generation 통합 (6장)	gemma4:e4b 연결, 20건 샘플	0.800	0.800

6.3 정성 평가 결과

정설아 — EXAONE-3.5-7.8B | Qwen3-Embedding-0.6B (50 건 샘플)



[그림 4] 타입별 정성 평가 결과 (EXAONE-3.5-7.8B / Qwen3-Embedding-0.6B, 50건 샘플)

타입	Good	Bad	애매	정답률
A — 단순 사실	4	3	3	40%
B — 비교/계산	4	3	3	40%
C — 대화 맥락	5	4	1	50%
D — 세부 조항	0	7	3	0% 
E — 구어체	4	5	1	40%
합계	17	22	11	34% (Good 17 / 전체 50건)

정봄 — EXAONE-3.5-7.8B | Qwen3-Embedding-0.6B (15 건 Quick Eval)

타입	Good	Bad	애매	정답률
A — 단순 사실	3	1	0	75%
B — 비교/계산	3	0	2	60%
C — 대화 맥락	1	1	0	50%
D — 세부 조항	1	1	0	50%
E — 구어체	2	0	0	100%
합계	10	3	2	67% (Good 10 / 전체 15건)

반복 오류 패턴

오류 유형	대표 케이스	개선 방향
예산 혼동 (다른 사업 예산 반환)	Q061, Q121, Q399 등	발주기관/사업명 메타 필터링 강화
과잉 거부 (존재 정보 거부)	Q001, Q018, Q357 등	체크 검색 범위 확대, 임계값 조정
복합 질문 부분 누락	Q368, Q153, Q213 등	프롬프트에서 요구 항목 명시 분리

6.4 개선사항

● Critical

- Evidence Card Number Hit Rate = 0% — 증거 카드 수치 추출 파이프라인 근본 재설계 필요
- RAGAS Faithfulness null — gemma4:e4b 가 RAGAS 파서 형식 미준수, 측정 불가

● High

- Q260 트레이드오프 — V2 에서 False Refusal 해소됐으나 수치 오답으로 전환 (수치 근거 검증 로직 필요)
- Q001/Q015/Q325 지속 False Refusal — V1·V2 모두 발생, 케이스별 원인 분석 필요
- Q129 False Positive Amount — core_amount_boost(0.6) 과적용 가능성 검토 필요 (V1·V2 공통)

● Medium

- V2 MRR 하락 (-0.075) — 관련 체크 상위 정렬 능력 저하
- Answer Number Hit Rate 54.5% — 수치 포함 질문의 절반 가까이 정확 수치 도출 실패

7. 서빙

7.1 BidMate UI 구현

박민성이 Streamlit 기반 BidMate RFP Assistant UI를 최종 구현하였다. prom09 노트북 커널과 파일 기반 통신(request/response JSON) 구조로 연결하여 실시간 질의응답이 가능하도록 설계하였다.

기능	설명
다크테마 UI	BidMate 브랜딩 적용, 전문적 인터페이스
사이드바 히스토리	대화 히스토리 로컬 저장 (chat_history.json)
예시 질문 버튼	자주 묻는 유형별 예시 질문 원클릭 입력
출처 Expander	체크 내용 클릭 시 펼쳐보기
파일 기반 통신	prom09 커널 ↔ Streamlit 간 JSON 파일 통신

7.2 Ollama + EXAONE 환경 구성

단계	내용
Ollama 설치	curl -fsSL https://ollama.com/install.sh sh (관리자 계정 우회)
EXAONE 모델	ollama pull hf.co/lmstudio-community/EXAONE-3.5-7.8B-Instruct-GGUF (4.8GB)
gemma4 모델	ollama pull gemma4:e4b (서비스용, 57 t/s)

8. 협업 회고

8.1 프로젝트 타임라인

날짜	주요 이벤트
05.14	프로젝트 킥오프. GitHub·Notion 세팅 완료. 데이터 파싱 착수.
05.15	Retrieval 베이스라인 구축. ChromaDB naive retrieval 완성. 청킹 실험 시작.
05.18~19	HWP/PDF 통합 청킹 완료. Retrieval V4 Hybrid Search 도입. eval셋 500건 확정.
05.20~21	모델 선정 완료 (gemma4:e4b). Retrieval V6 Hybrid+Reranker 달성.
05.22	end-to-end 1회 완성 (멘토 제안 반영). 통합 평가 파이프라인 구성.
05.26~27	프롬프트 v7e 확정. Retrieval V9 데이터 확정. ChromaDB Qwen3 구축 완료.
05.28	정성 평가 착수. Tool Calling 도입. Streamlit 서빙 구현.
05.29	Retrieval V12 완성 (시나리오 A 전환). 정성 평가 보고서 완성.
06.01~04	최종 보고서 작성 및 발표 준비.

8.2 주요 의사결정

시점	결정 사항	배경
05.14	시나리오 A 우선 진행 방향 확정	API 비용 및 의존도 문제
05.15	advanced 텍스트 → 원본 바이너리 파싱 전환	표 데이터 누락 발견
05.21	멘토 제안 — 1개 파이프라인 완성 후 실험 변경	방향 정렬 및 속도 조절
05.28	Hit@K 1.0 맹신 금지, 정성 평가 병행	멘토 피드백
05.28	금액 계산 시 Tool Calling 활용	수치 정확도 향상
05.29	임베딩 모델 Qwen3로 최종 확정	성능 검증 및 팀 합의

8.3 트러블슈팅 하이라이트

문제	영향	해결 방법	담당
HWP 표 추출 7회 시도	파싱 지연	size%36==0 조건 확정	정설아
PDF doc_id 충돌	체크 중복 (→51,465)	파일형식 기반 구분 저장	정설아
GCP VM 반복 다운	작업 유실	순차 사용 룰, Colab 병행	유연정
ChromaDB HNSW 비호환	Win→Mac 이식 불가	벡터 이식 방식(3~5분)	박민성
D타입 임계값 E타입 영향	E타입 0.9 하락	임계값 0.3→0.2 조정	박찬영
nDCG@10=0.0 버그	평가 지표 신뢰성 저하	relevance label 매핑 방식 수정	박찬영

8.4 팀원별 기여

팀원	핵심 기여
유연정 (PM)	GitHub/Notion 환경 세팅, 500건 평가셋 구축, 정량/정성 평가 설계, 팀 일정 관리
정설아	HWP 바이너리 파싱 완성, 청킹 파이프라인, ChromaDB 구축, 수치 데이터 고도화
정봄	PDF 파싱·청킹, ChromaDB 구축 보조, 정성 평가 15건
박찬영	Retrieval V1~V12 전 과정, Hybrid-BGE-Reranker-Recall@10 구현
박민성	모델 선정 실험, 프롬프트 v1~v7e, 통합 파이프라인, Tool Calling 도입, Streamlit 서빙

9. 결론 및 향후 과제

9.1 달성 성과

항목	목표	달성 결과
Hit@5	≥ 0.80	0.918 ☒
MRR	≥ 0.60	0.829 ☒
API 비용	최소화	\$0 (완전 로컬) ☒
청크 규모	충분한 데이터	51,465개 (초기 2,922개 대비 17.6배) ☒
서빙	Streamlit UI	BidMate Assistant 구현 ☒

9.2 향후 과제

단기

1. D 타입 Hallucination 전용 평가 로직 구현 (Hit@k/MRR 과 분리)
2. Evidence Card 수치 추출 파이프라인 재설계 (현재 0% → 개선 필요)
1. False Refusal 지속 케이스 (Q001, Q015, Q325) 케이스별 원인 분석
2. RAGAS faithfulness 측정 복구 (전용 LLM 활용)

중장기

3. 평가셋 품질 개선 — 누수 질문(139 건) 제거 후 clean 셋 기준 재평가
4. Reranker 활성화 실험 — MRR 회복 가능성 검토
5. 세부 조항 문서 전용 청킹 전략 분리
6. 서비스 완성도 강화 — Ollama-ChromaDB 웹 연동, 외부 접속 환경 구성

9.3 총평

본 프로젝트는 665개 HWP 파일의 바이너리 직접 파싱이라는 난이도 높은 도전을 포함하여, 데이터 처리 → Retrieval → Generation → 서빙까지 완전한 RAG 파이프라인을 3주 만에 구축하였다. Retrieval 파이프라인을 구축하였으며, API 비용 없이 완전 로컬 환경(\$0)에서 서비스 가능한 시스템을 완성하였다. Generation 파트의 수치 추출 정확도와 D타입 평가 로직은 향후 개선 과제로 남아 있다.